

From Black-Box to Explainability

Probabilistic Automata for Time Series Analysis

Yazılım Geliştirme Dersi — 2. Proje
Kerem Ünal & Efekan Tosmak
Haziran 2026

Bu rapor, iki farklı zaman serisi anomali tespit yaklaşımının — derin öğrenme modelleri (LSTM, GRU, 1D-CNN) ve Probabilistic Automata — SKAB ve BATADAL veri setleri üzerindeki karşılaştırmalı analiz sonuçlarını sunmaktadır.

1. Temel Performans ve Stabilité

Aşağıdaki tablo, modellerin iki farklı veri seti üzerindeki ortalama F1-skorlarını ve 5 farklı random seed [42, 123, 2026, 7, 999] ile elde edilen standart sapma değerlerini göstermektedir.

Tablo 1: Model Performansı ve Stabilitesi (Ortalama F1-score $\pm$ Standart Sapma)

Model	SKAB F1 (mean $\pm$ std)	BATADAL F1 (mean $\pm$ std)
LSTM	0.8938 $\pm$ 0.0395	0.5813 $\pm$ 0.0717
GRU	0.9025 $\pm$ 0.0377	0.5704 $\pm$ 0.0572
1D-CNN	0.8977 $\pm$ 0.0471	0.4666 $\pm$ 0.0899
Automata	0.4645 $\pm$ 0.0171	0.1556 $\pm$ 0.0000

2. Gürültü ve Unseen Veri Analizi (Robustness)

Modellerin veri kalitesindeki düşüşlere ve daha önce karşılaşılmamış örüntülere (unseen patterns) karşı direnci Gaussian gürültü (std = 0.1) eklenerek ve unseen senaryo ile ölçülmüştür. Unseen Oranı sütunu Automata'nın test verisinde eğitim sözlüğünde bulunmayan örüntülerle karşılaşma oranını göstermektedir.

SKAB Veri Seti

Tablo 2a: SKAB — Gürültü Etkisi ve Unseen Analizi

Model	Orijinal F1	Gürültülü F1	F1 Değişimi
LSTM	0.8938	0.8880	-0.0058
GRU	0.9025	0.8921	-0.0104
1D-CNN	0.8977	0.8949	-0.0028
Automata	0.4645 (unseen: 0.0041)	0.4688	+0.0043

BATADAL Veri Seti

Tablo 2b: BATADAL — Gürültü Etkisi ve Unseen Analizi

Model	Orijinal F1	Gürültülü F1	F1 Değişimi
LSTM	0.5813	0.5462	-0.0351
GRU	0.5704	0.5616	-0.0088
1D-CNN	0.4666	0.4270	-0.0396
Automata	0.1556 (unseen: 0.0291)	0.1978	+0.0422

3. Çapraz Veri Seti (Cross-Dataset) Karşılaştırması

Aynı model her iki veri seti üzerinde bağımsız olarak eğitilip test edilmiştir. Tablo, her veri seti için orijinal senaryodaki F1 değerlerini karşılaştırmaktadır.

Tablo 3: Cross-Dataset Performans Karşılaştırması

Model	SKAB F1	BATADAL F1	Fark (SKAB – BATADAL)
LSTM	0.8938	0.5813	+0.3125
GRU	0.9025	0.5704	+0.3321
1D-CNN	0.8977	0.4666	+0.4311
Automata	0.4645	0.1556	+0.3089

DL modelleri SKAB'da belirgin şekilde daha yüksek F1 elde etmektedir (fark ≈ 0.31 – 0.43). BATADAL'ın daha yüksek sınıf dengesizliği (%12 anomali) ve 43 boyutlu sensör uzayı bu farkın başlıca nedenleridir. Automata da SKAB'da daha iyi sonuç vermektedir (fark ≈ 0.31).

4. Automata Parametre ve Süre Analizi

Automata modelinin Window Size ve Alphabet Size parametrelerinin F1 ve state sayısına etkisi aşağıda özetlenmiştir (BATADAL verisi üzerinde).

Tablo 4: Automata Parametre Duyarlılık Analizi — F1-score (BATADAL)

Window Size	as=3	as=4	as=5	as=6
ws=3	0.2081	0.1271	0.1698	0.1139
ws=4	0.1522	0.1818	0.1797	0.0541
ws=5	0.0788	0.2022	0.2127	0.2268
ws=6	0.2440	0.2081	0.2120	0.1718

Tablo 4b: State Sayısı (BATADAL)

Window Size	as=3	as=4	as=5	as=6
ws=3	26	59	112	178
ws=4	76	176	258	338

ws=5	170	298	367	425
ws=6	200	304	341	375

Aşağıdaki tablo modellerin ortalama eğitim ve çıkarım sürelerini göstermektedir (5 seed ortalaması, BATADAL verisi).

Tablo 5: Modellerin Çalışma Süresi Karşılaştırması

Model	Eğitim Süresi (sn)	Çıkarım Süresi (sn)
LSTM	3.6	0.01
GRU	6.2	0.03
1D-CNN	1.1	0.006
Automata	0.05	0.001

5. İstatistiksel Analiz (McNemar Testi)

Model farklarının anlamlılığı McNemar testi ile değerlendirilmiştir. $p < 0.05$ anlamlı fark gösterir ($\checkmark$), $p \geq 0.05$ anlamsızdır ($\times$).

BATADAL

Tablo 6a: BATADAL — McNemar Testi Sonuçları

Karşılaştırma	Original p	Original	Noisy p	Noisy
LSTM vs GRU	0.0000	$\checkmark$	0.0000	$\checkmark$
LSTM vs CNN	0.0055	$\checkmark$	0.0000	$\checkmark$
GRU vs CNN	0.0002	$\checkmark$	0.0001	$\checkmark$

SKAB

Tablo 6b: SKAB — McNemar Testi Sonuçları

Karşılaştırma	Original p	Original	Noisy p	Noisy
LSTM vs GRU	0.0002	$\checkmark$	0.0002	$\checkmark$
LSTM vs CNN	0.0002	$\checkmark$	0.0000	$\checkmark$
GRU vs CNN	0.6728	$\times$	0.0342	$\checkmark$

6. Açıklanabilirlik Modülü — Örnek Çıktı

Automata modeli her tahmin için deterministik ve yeniden üretilebilir açıklamalar üretmektedir. Aşağıda bir unseen pattern durumu için üretilen JSON çıktısı gösterilmektedir.

```
{
  "time_step": 5,
  "state": "aab",
```

```

    "pattern": "adc",
    "status": "unseen",
    "mapped_to": "abc",
    "distance": 1,
    "transitions": { "aab->abc": 0.720000 },
    "transition_probability": 0.720000,
    "state_anomaly_rate": 0.031250,
    "anomaly_score": 0.412000,
    "probability": 0.720000,
    "decision": "normal",
    "confidence": 0.908000
  }

```

Güven skoru hesaplaması:

$$confidence = 1.0 - |anomaly_score - threshold|$$

Anomali skoru:

$$anomaly_score = 0.6 \times state_anomaly_rate + 0.4 \times (1 - transition_probability)$$

Path probability:

$$P(sequence) = \prod P(S_i \rightarrow S_{i+1})$$